

Instituto Matemático Actuarial Mexicano

Módulo de Visualización de Datos

Reto de aplicación

Análisis del catálogo de Netflix mediante NumPy, Pandas
y Visualización de Datos

Instructora: M. en A. D. Jessica Santizo Galicia
Fecha de entrega: 12 de junio de 2026, 23:59 horas

Objetivo

El objetivo de este reto es poner en práctica los contenidos revisados durante el módulo realizando las siguientes actividades:

- Recuperar información utilizando NumPy y Pandas.
- Analizar e interpretar información contenida en diferentes archivos.
- Aplicar operaciones de selección, filtrado y transformación de datos.
- Integrar información proveniente de varios conjuntos de datos.
- Aplicar técnicas de agrupación y análisis.
- Construir visualizaciones para comunicar resultados.
- Exportar resultados a un archivo Excel con múltiples hojas de trabajo.

Introducción

Netflix es una de las plataformas de streaming más utilizadas a nivel mundial. Su catálogo incluye miles de películas y series provenientes de distintos países, géneros y clasificaciones de audiencia.

En este reto trabajarás con información pública del catálogo de Netflix. A partir de un archivo original deberás generar varios conjuntos de datos relacionados entre sí para posteriormente analizarlos utilizando las herramientas vistas durante el módulo.

Trabajarás con cuatro archivos diferentes. Uno contendrá la información general de los títulos disponibles en Netflix, mientras que los otros tres contendrán información relacionada con países de origen, géneros y clasificaciones de audiencia.

El objetivo será integrar correctamente la información de todos los archivos para responder preguntas relacionadas con la composición del catálogo, los países que generan más contenido, los géneros más frecuentes y la evolución del contenido a través del tiempo.

Fuente de datos

Descarga el dataset público desde la siguiente liga:

<https://www.kaggle.com/datasets/shivamb/netflix-shows>

Instrucciones

Para poder concluir exitosamente este reto, necesitarás llevar a cabo los siguientes pasos:

1. Descarga el dataset público indicado anteriormente.

2. Abre el archivo descargado para conocer su estructura y familiarizarte con la información contenida en él.
3. Crea un notebook de Jupyter para resolver el reto utilizando Python.
4. A partir del archivo original genera los siguientes cuatro conjuntos de datos:

a) Datos generales de títulos

Debe incluir:

- Identificador del título.
- Tipo de contenido.
- Nombre del título.
- Director.
- Año de lanzamiento.
- Duración.

b) Datos de países

Debe incluir:

- Identificador del título.
- País.

Si un título tiene más de un país registrado, cada país deberá almacenarse en una fila independiente.

c) Datos de géneros

Debe incluir:

- Identificador del título.
- Género.

Si un título tiene más de un género registrado, cada género deberá almacenarse en una fila independiente.

d) Datos de clasificaciones

Debe incluir:

- Identificador del título.
- Clasificación de audiencia.
- Fecha de incorporación a Netflix.

5. Guarda cada conjunto de datos en un archivo CSV independiente.
6. Crea cuatro DataFrames en Pandas para cargar el contenido de los archivos generados.
7. Realiza una exploración inicial de los datos para identificar:
 - Número de registros.
 - Número de variables.

- Tipos de datos.
- Valores faltantes.
- Variables numéricas.
- Variables categóricas.

8. Para todos los registros que no cuenten con información de país, género o clasificación, asigna el valor:

No registrado

9. Utilizando NumPy calcula:

- a)* Año promedio de lanzamiento.
- b)* Mediana de los años de lanzamiento.
- c)* Desviación estándar.
- d)* Año mínimo de lanzamiento.
- e)* Año máximo de lanzamiento.

10. Genera una nueva variable que permita identificar la década de lanzamiento del contenido.

11. Integra correctamente la información de los cuatro DataFrames en un único DataFrame.

12. Utiliza las técnicas vistas durante el módulo para realizar operaciones de:

- Selección de columnas.
- Creación de Series.
- Filtrado.
- Extracción de información.
- Ordenamiento.
- Transformación de variables.

13. Utiliza operaciones de:

- Merge.
- Join.
- Concat.

para integrar adecuadamente la información.

14. Responde las siguientes preguntas utilizando Pandas:

- a) ¿Qué porcentaje del catálogo corresponde a películas y qué porcentaje corresponde a series?
 - b) ¿Cuáles son los diez países con mayor cantidad de títulos disponibles?
 - c) ¿Cuáles son los diez géneros más frecuentes dentro del catálogo?
 - d) ¿Cuál es la clasificación de audiencia más común?
 - e) ¿Qué década concentra la mayor cantidad de contenido?
15. Utiliza GroupBy para generar los análisis necesarios.
16. Construye al menos cuatro visualizaciones utilizando Matplotlib y Seaborn. Las visualizaciones deberán incluir:
- Título.
 - Etiquetas de ejes.
 - Formato adecuado para facilitar su interpretación.
 - Breve interpretación.

Como mínimo deberán incluirse las siguientes:

- a) Comparación entre películas y series.
 - b) Diez países con más títulos.
 - c) Diez géneros más frecuentes.
 - d) Distribución de años de lanzamiento.
17. Exporta los resultados obtenidos a un archivo XLSX.
- Cada consulta deberá almacenarse en una hoja de trabajo independiente.

Entregable

1. Guarda todos los cambios realizados en tu notebook de Jupyter. Asegúrate de dejar visibles todas las ejecuciones de las celdas.
2. Renombra el notebook utilizando el siguiente formato:

`Reto_APELLIDOS_NOMBREdel participante.ipynb`

3. Genera un archivo Excel con los resultados obtenidos y nómbralo:

`Reto_APELLIDOS_NOMBREdel participante.xlsx`

4. Incluye también:

- El archivo original descargado.
- Los cuatro archivos CSV generados.
- El notebook de Jupyter.
- El archivo Excel con resultados.

5. Comprime todos los archivos en un único archivo ZIP utilizando el nombre:

`Reto_APELLIDOS_NOMBREdel participante.zip`

6. Envía el archivo ZIP al correo:

`js@ciencias.unam.mx`